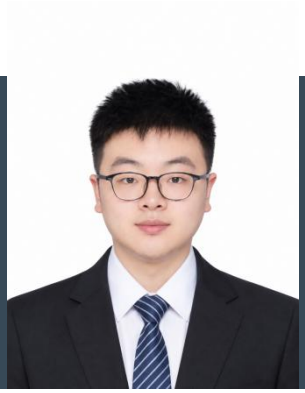


王金龙 PERSONAL RESUME

性别：男　　年龄：24　　Github：https://github.com/adventurer002

邮箱：Dh20020327@163.com　　个人博客：https://rffj.top

个人优势

核心语言与后端基建:

精通 Python/FastAPI 及异步并发，熟练运用 SQLAlchemy 处理复杂业务。掌握 Linux 运维、Docker/Nginx 部署及 GitHub 代码协同。

Agent 工程与 Workflow 编排:

深度掌握 LangGraph 复杂编排，能灵活处理上下文增强与查询重写。具备 Pydantic 结构化输出、Checkpointer 状态持久化及 SSE 流式响应的设计经验。化及 SSE 流式输出机制。

RAG 全链路与向量检索生态:

精通 RAG 全链路（文档切片、混合检索、Cross-Encoder 调优）及 Prompt 评估优化。熟练应用 PostgreSQL 及 Milvus/ChromaDB 向量数据库，掌握 BGE 系列开源 Embedding 模型落地与语料数据治理。

模型微调、推理优化与评估闭环:

熟悉 SFT/DPO 微调及 ShareGPT 等格式的数据构建。掌握 LLM 推理优化（Prefix Caching、TTFT 控制、动态路由），具备自动化评测与 badcase 回流驱动的持续优化经验。

熟全栈开发与真实场景落地:

熟悉 Vue/React 框架及 ASR/TTS 语音交互链路。具备丰富的电商 AI（私域导购、直播切片、内容生成）落地经验，能将底层能力切实转化为业务闭环。

重庆外企德科 2026.3-2026.7

AI 应用开发

围绕公司电商业务中的私域销售、独立站售前咨询、内容生产、商品素材、直播内容和销售培训场景，参与并牵头 AI 应用体系从 0 到 1 建设，将大模型能力落到真实电商转化链路中。

重庆数字化城市建设和治理中心 2024.4-2025.3

应用开发与贯通

负责相关应用开发与系统贯通。协同多部门开展需求调研、流程梳理和接口联调，推进跨系统数据共享与平台贯通，打通业务堵点，支撑城市治理场景落地和业务闭环。

项目经历

AI 实时语音对话智能客服

2026.3-2026.6

AI 技术负责人

项目规划：

把销售的对话数据经中台清洗后建 RA 知识库，构建实时语音对话的智能客服，承接商品咨询到引导下单的全流程。

RAG 检索提效：采用自定义切片、混合检索、Int8 量化及 Metadata 过滤，存储直降 75%；引入轻量 Rerank 优化语音场景，检索速度提升 4 倍且强化了专有名词命中。

推理链路优化：精简提示词并固定检索排序，深度利用 Prefix Caching 与 KV Cache，将复杂场景首字延迟（TTFT）从 15s 压缩至 2s 内；设计 Token 分级控制策略提升资源利用率。

多模态体验赋能：对接素材中心，实现依据语义自动召回图文/视频并进行多模态混排输出，丰富终端客服交互形态。

大模型数据飞轮：实现 Prompt 自动化评测与负样本重构；将优质交互数据回流中台，反哺后续模型微调（Fine-tuning），形成“数据-模型-业务”的完整闭环。

AI 数据中台

2026.3-2026.7

AI 技术负责人

项目规划：

整个 AI 体系的底座：所有跟 AI 相关的业务（客服 / 微调 / 考核 / 素材 / 直播）都从这里取数。。

设全链路数据基建：搭建从微信 SQLite 到多下游应用的数据流水线，完成解析、去重及关系映射，确立不可变的原始语料库。

高标准脱敏与过滤：构建 9 级优先级过滤机制与三层冗余脱敏引擎，严格执行隐私保护与价格脱敏红线，保障模型训练合规安全。

微调语料自动化生产：基于时间窗与角色合并对话，结合自动预标注与人工审核，一键输出 ShareGPT/Alpaca 格式语料，直通模型精调。

知识图谱与数据飞轮：利用 LLM 提取结构化知识落入向量库赋能 RAG；作为核心总线反向汇集音视频等多模态业务数据，形成“生成即沉淀”的闭环。

自媒体智能内容运营 Agent

2026.3-2026.5

AI 技术负责人

项目规划：

电商要持续产出商品图、商品介绍、宣传文案，做一个内容生成 Agent 降本增效；产出的图片直接关联到素材中心，反哺多模态知识库。

LangGraph 工作流架构：基于 LangGraph 子图拆分解耦复杂生成流程，通过 Checkpointer 实现图状态的持久化、无损回滚与节点级重试。

性能与高并发优化：深度集成 SSE Token 级实时流，TTFT 降低 60%；运用异步并发（asyncio）与指数退避重试改造批量配图链路，生成耗时缩减 70%。

低成本模型路由策略：自研全链路追踪与成本核算组件，实施多模型动态路由，配合 Pydantic 结构化输出，降低 40% LLM 推理成本。

系统基建与可观测性：接入 LangSmith 监控链路，问题定位缩至分钟级；构建 Mock 测试开关，效率提升 3 倍；引入熔断与限流机制保障高可用。

数据资产闭环：产出的多模态内容无缝汇入素材中心，自动转化为 AI 客服的交互知识资产，实现业务体系互联互通。

基于MCP协议的多Agent共享服务集群

2026.6-2026.7

AI 技术负责人

项目规划：

随着 AI 项目越来越多，做架构层面的统一收口：把 LLM 网关、RAG、记忆、Prompt 抽成共享基础设施，让所有业务（含数据中台）复用同一套底座。

多租户微服务架构：基于 MCP 协议将四大 AI 核心能力（LLM/RAG/记忆/Prompt）微服务化；构建 FastAPI 中间件网关，实现多租户 API Key 认证、Token 计费管控与全链路追踪。

模型路由与 Prompt 热更：实现 LLM 动态路由与 YAML 热切换，兼容多模态向量化；搭建统一 Prompt 模板中心，实现服务端动态渲染，解耦提示词工程与业务逻辑。

多租户知识库与双层记忆：基于 Viking DB 与语义切分构建物理隔离的自助 RAG 接入服务；首创“项目级会话+用户级画像”的双层记忆架构，实现多 Agent 间的认知事实跨域同步。

流水线编排与云原生部署：抽象 Agent 纯无状态 7 步流水线；基于阿里云 Serverless 部署容器集群，打通灰度发布与 SIGTERM 优雅停机，保障企业级高可用。

教育经历

重庆财经学院

2021.9-2025.7

智能科学与技术 | 本科

在校期间始终保持高度的学习热情与实践精神，参与校园创新项目，团队协作完成方案并获校级奖项。坚持兼职与实习，平衡学业与社会实践，锻炼了扎实的专业能力与高效的时间管理