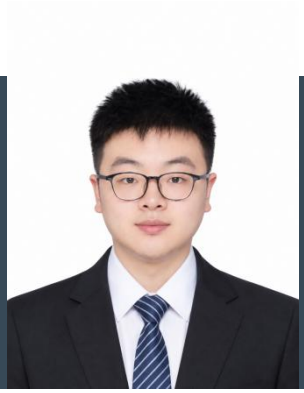


王金龙 PERSONAL RESUME

性别：男　　年龄：24　　Github：https://github.com/adventurer002

邮箱：Dh20020327@163.com　　个人博客：https://rffj.top

个人优势

- **熟悉电商 AI 应用落地：** 具备私域销售、独立站售前导购、商品素材、直播内容、销售培训等业务场景经验能将 AI 能力转化为销售提效、知识复用和业务闭环。
- **熟悉 Agent 与 Workflow 工程编排：** 掌握 LangGraph 复杂编排，熟练处理 context enrichment / query rewrite 子流程。具备 Pydantic / JSON Mode 结构化输出、节点级重试、Checkpointer 状态持久化及 SSE 流式输出设计经验。
- **精通 RAG 检索增强与 Prompt 工程：** 精通 RAG 全链路，熟练应用文档切片、混合检索、Cross-Encoder Rerank 与 Top-K 调优。具备 Prompt 版本管理、灰度验证及负样本优化能力。
- **熟悉大模型微调数据构建流程：** 理解 SFT、DPO、RLHF 的差异及适用场景，掌握从销售对话清洗、脱敏、标注到 ShareGPT /Alpaca /OpenAI JSONL 数据导出的微调样本构建方法。
- **熟悉 LLM 推理性能优化与音视频交互：** 理解 Prefix Caching、KV Cache、TTFT 等 LLM 推理性能优化及多模型动态路由策略。熟悉 RTC 弱网优化及 ASR/TTS 语音交互链路。
- **熟悉数据治理与知识资产沉淀：** 具备微信/WhatsApp 对话、直播 ASR、商品素材文本的清洗、脱敏、审核、标签化和多下游复用经验
- **熟悉 PostgreSQL 与向量数据库应用：** 能够设计语料分层、任务状态、素材 metadata、题库评分、Trace 日志等数据结构，并结合向量检索支撑 RAG 和素材搜索。
- **熟悉模型评估与线上反馈闭环：** 掌握自动化指标、人工盲评、A/B 对比、低置信度问题、人工接管、用户负反馈和 badcase 回流驱动的持续优化方法。
- **熟悉高并发后端与系统基建：** 精通 Python 开发与 FastAPI 框架，深入理解异步并发与接口超时控制。掌握 Docker / Nginx 部署及监控预警。

重庆兴诺汇科技有限公司　　2025.6-2026.8

AI 应用开发

围绕公司电商业务中的私域销售、独立站售前咨询、内容生产、商品素材、直播内容和销售培训场景，参与并牵头 AI 应用体系从 0 到 1 建设，将大模型能力落到真实电商转化链路中。

重庆数字化城市建设和治理中心　　2024.4-2025.3

应用开发与贯通

负责相关应用开发与系统贯通。协同多部门开展需求调研、流程梳理和接口联调，推进跨系统数据共享与平台贯通，打通业务堵点，支撑城市治理场景落地和业务闭环。

项目经历

AI 实时语音对话智能客服

2025.7-至今

AI 技术负责人

项目规划：

把销售在微信/WhatsApp 的对话数据经中台清洗后建立 RAG 知识库，构建可实时语音对话的智能客服，承接商品咨询到引导下单的全流程。

- 知识库直接消费数据中台导出的 RAG 数据，采用自定义标识符切片解决语义截断，应用 HNSW_HYBRID 混合检索 + Int8 量化，构建 Metadata 标签过滤机制，存储空间降低 75%。
- 优化 LLM 推理链路：固定 RAG 检索片段排序、合并 System Prompt 消息体，深度触发模型前缀缓存（Prefix Caching）与 KV Cache，将复杂 RAG 场景的首字延迟（TTFT）从 15s 压缩至 2s 内；针对业务做模型选型与资源池优先级调优。
- 针对语音场景通过降维+精简 Limit 策略，引入 base-rerank 轻量模型，动态平衡 dense_weight 权重，在保持语义理解的同时显著提升专有名词命中率，检索速度提升 4 倍。
- 接入多模态素材中心（详见项目六），命中图片、视频等素材后以「文字 + 图片 + 视频」混排分条返回，让语音/图文客服具备多模态应答能力。
- 接入微调后的模型作为 LLM 层（详见项目七），通过缩短 system prompt 进一步降低 TTFT；并建立 Max Token 分级控制模型，按 95% 覆盖率边界动态配置推理/输出比例，提升单请求 Token 利用率。
- 用 Prompt Pilot 管理提示词，构建评测集实现自动化评分与版本对比；对负样本用智能优化算法做提示词重构，并将高质量样本回流数据中台沉淀，为后续模型精调（Fine-tuning）储备语料，保障回复的准确性与一致性。

AI 数据中台

2025.7-至今

AI 技术负责人

项目规划：

整个 AI 体系的底座：所有跟 AI 相关的业务（客服 / 微调 / 考核 / 素材 / 直播）都从这里取数。。

- 设计 ETL → 原始库 → 暂存区 → 人工审核 → 多下游的全链路数据流水线：从微信本地 SQLite（MSG0-5.db + MicroMsg.db）抽取消息，完成通讯录 wxid→显示名映射、群消息发送者解析、时间过滤与 (session,timestamp,content) 去重后落 raw_chats 原始库（不可变）。
- 构建 DataFilter 内容过滤 + 脱敏引擎：按 9 级优先级分类（系统/媒体/过短/敏感/闲聊/垃圾/高价值）丢弃噪声，对手机号、身份证、银行卡、邮箱、API Key 做正则脱敏；设计多层冗余脱敏（清洗时 + 写入时 + 导出时三次），并将价格脱敏设为硬红线，杜绝微调模型泄露真实定价。
- 实现「一键清洗」对话块构建：基于 5 分钟时间窗切分会话、合并同角色连续消息、去重，并做自动预标注（分类 / 质量分 / Q&A 提取 / 敏感标记）；高质量数据进 staging_conversations 暂存区，经人工 approve/reject/编辑后作为唯一可信数据源。
- 训练数据导出清洗（价格脱敏、风格修复、过短过滤、过长截断、占位符清理），一份数据多格式导出：ShareGPT / Alpaca / OpenAI JSONL（供微调）与 RAG CSV（供知识库），打通项目七的微调链路。
- 构建向量知识库下游：对 approved 数据做 embedding（DashScope text-embedding-v3）写入 knowledge_chunks，并经 LLM 提炼为结构化 knowledge_articles（场景 / 客户话术 / 推荐回复 / 置信度），同时为项目一的 RAG 检索和项目六的 AI 考核出题提供素材。
- 中台作为数据总线对接全业务：项目五直播切片的 ASR 转写结果回流入库留存，项目六素材中心的图片/视频反

向补充多模态语料，真正实现"AI 的一切都是数据"的闭环。

AI 直播切片 Agent

2025.8-至今

AI 技术负责人

项目规划：

公司有直播带货场景，把直播回放交给 AI 自动找精彩片段、配标题文案，减轻剪辑师工作；转写结果同步回流数据中台留存复用。

- 设计「视频 → AI 找精彩片段 → 输出短视频切片」端到端 Agent，三层架构：React 19 + FFmpeg.wasm 前端、FastAPI + SQLAlchemy 2.0 后端、Groq Whisper + DeepSeek 外部 AI。
- 关键设计浏览器内 FFmpeg.wasm 提音频：用 WORKERFS 零拷贝挂载源文件，转码为 16kHz/单声道/64kbps MP3，把 2.5GB 视频压到 ~30MB 再上传，上传体积降低 99%，用户等待从分钟级降到秒级。
- 用 PostgreSQL 构建任务队列，API 写入 pending 秒回，Task Runner 后台协程每秒抢占一条串行执行 Pipeline，进程崩溃时启动自动重置「进行中」任务回 pending，实现零云依赖 + 崩溃可恢复。
- 构建可观测 Pipeline（音频准备 → ASR → LLM 分析 → 切片 → 入库）：进度统一写库 + SSE 每秒读库推送，进度源唯一、断线可续、多端一致；长音频用 ffmpeg -c copy 按 25 分钟无损分段串行转录，时间戳加 offset 还原绝对时间轴。
- LLM 分析做按 ~6000 token 分批 + 双向重叠去重（重叠 >30% 取高分项），支撑 6 小时长视频不爆上下文；内置 直播/面试/讲座场景化 Prompt，按场景切换切片时长与去重阈值；输出爆款分、推荐文案，并支持按需生成抖音风格标题与剪辑思路。
- 导出阶段二次复用 FFmpeg.wasm 在浏览器内按 AI 时间段批量裁切打包 ZIP，后端不碰重型转码；ASR 转写结果回写数据中台留存，为后续内容分析/训练备用。

自媒体智能内容运营 Agent

2025.10-至今

AI 技术负责人

项目规划：

电商要持续产出商品图、商品介绍、宣传文案，做一个内容生成 Agent 降本增效；产出的图片直接关联到素材中心，反哺多模态知识库。

- 基于 LangGraph 构建多阶段内容生成工作流，用 SubGraph 子图将选题、写作、配图拆为独立编排单元；通过 PostgreSQL Checkpointer 持久化状态，支持任意历史节点回滚与增量重试。
- 设计 MetricsContext 上下文管理器做 LLM 全链路追踪，采集各节点 Token 消耗、推理延迟、错误率，结合火山引擎定价模型完成成本核算，为模型选型提供数据支撑。
- 实现 SSE 流式输出与 LangGraph astream_events 深度集成，监听 on_chat_model_stream 捕获 Token 级实时流，配合前端 ReadableStream 将感知 TTFT 降低 60%，并保证流式/非流式下 Checkpointer 数据结构一致。
- 针对配图批量生成做异步并行优化：asyncio.gather + run_in_executor 将同步 API 封装为协程并发执行，引入指数退避重试（1s→2s→4s）应对服务抖动，整体生成耗时缩减 70%。
- 构建多模型动态路由：简单任务走轻量 Flash 模型、复杂任务走旗舰模型，配合 with_structured_output 做 Pydantic Schema 强约束，并用 JSON Mode + 手动解析解决结构化输出与 Token 统计不兼容问题，降低 40% 推理成本。
- 设计环境变量驱动的 Mock 开关体系（llm/image/checkpointer）解耦外部服务，配合 Swagger UI 可视化评测与 Ngrok 公网映射，将本地调试效率提升 3 倍；接入 LangSmith + structlog + request_id 实现全链

路可观测，问题定位从小时级压缩到分钟级。

- 基于 SlowAPI 接口限流 + 熔断降级 + /health 健康检查 + 优雅关闭保障容器化高可用；生成的商品图直接写入素材中心（项目六），经离线增强后成为 AI 客服的多模态回复素材，形成"生成即沉淀"的闭环。

基于 MCP 协议的多 Agent 共享服务集群

2025.11-至今

AI 技术负责人

项目规划：

随着 AI 项目越来越多，做架构层面的统一收口：把 LLM 网关、RAG、记忆、Prompt 抽成共享基础设施，让所有业务（含数据中台）复用同一套底座。

- 将 LLM 网关、RAG 检索、会话记忆、Prompt 管理抽离为 4 个独立 MCP Server，经 Streamable HTTP 暴露标准化 Tool/Prompt 原语，新业务接入仅需写 Agent 编排层。
- 设计 REST → MCP 协议桥接网关，基于 FastAPI 构建四层中间件链（认证 → 日志 → 配额 → 路由），用 Trace ID 全链路追踪；内置 MCP Client Manager 管理短连接，按项目维度做 API Key 认证与 Token 配额计量，保障多租户安全隔离与成本管控。
- 构建统一 LLM 网关，实现逻辑模型名 → Endpoint 路由（auto/pro/lite），YAML 配置热切换业务无感；Embedding 兼容火山引擎 text 与 vision 两种向量化路径，Token 消耗统一回传配额模块扣减。
- 实现多租户 RAG 服务：基于火山引擎 Viking DB 按 project_id 划分独立 Collection 做物理隔离，按 Markdown 标题层级 + 段落边界语义切分，新项目调 ingest_document Tool 即可自助接入。
- 设计双层记忆架构：对话记忆按 project_id + session_id 隔离支持最近 N 轮召回；用户画像按 user_id 跨项目共享，基于 PostgreSQL UPSERT (ON CONFLICT DO UPDATE) 幂等写入，客服 Agent 自动提取用户事实（过敏/预算/偏好），写作 Agent 即时读取，实现跨项目用户认知同步。
- 基于 MCP 原生 Prompt 原语构建模板中心，YAML 定义参数 Schema、服务端渲染为 PromptMessage，模板修改即时生效无需重启，实现提示词工程与业务逻辑解耦。
- 实现 Agent 七步编排流水线（召回历史 → 读画像 → 检索知识 → 渲染 Prompt → LLM 推理 → 存记忆 → 提取事实），全部经 GatewayClient 统一调用，Agent 无状态、状态下沉到共享服务；各服务独立构建 Docker 镜像部署至阿里云 Serverless（FC/SAE），按拓扑分层发布、灰度 + 秒级回滚，SIGTERM 优雅终止保障在途请求不丢。

多模态素材中心 & AI 销售考核系统

2026.1-至今

AI 技术负责人

项目规划：

两件事一条数据线：素材中心统一管理商品图/详情/视频，为 AI 客服提供多模态回复能力，同时补充数据中台；中台导出的高质量知识又驱动 AI 销售考核，替代过去的人工培训。 A. 多模态素材中心（图片 / 视频 → 可被语义命中的多模态知识库）

- 设计统一向量底座 rag_assets：text/image/video 三模态共用一张表（pgvector 1024 维 + HNSW vector_cosine_ops），一条 SQL 跨模态召回；核心理念是不向量化媒体本身，而向量化其「检索文本」retrieval_text（“这张图/视频能回答什么问题”），与用户文本提问天然对齐。
- 实现人工即时命中（manual）路线：图片/视频上传时人工维护标题/描述/标签/分类，拼接为 retrieval_text 经 text-embedding-v3 入库即可被命中；隐私红线为命中返回打码版 TOS URL。
- 实现离线机器增强（enriched）路线：在同一行上用 OCR（RapidOCR）+ VLM（qwen-vl） 补图片文字与看

图描述、用 ASR + LLM 摘要补视频口播，人工内容在前、机器内容追加，重写 retrieval_text 并重新 embedding，召回相似度从 ~0.38 提升至 ~0.71；按 (source_table, source_id) UPSERT 幂等可反复回扫。

- 设计长视频按 ASR 时间戳分段为多条 rag_assets，media_url 携带 #t=秒数，命中后前端播放器直接跳转到精彩片段；统一应答按「文字必发、图≤3、视频≤1」混排，阈值递增（text 0.35 < image 0.40 < video 0.42）。

B. AI 销售考核系统（替代人工培训与考核）

- 实现 LLM 自动出题：消费数据中台产出的 knowledge_articles/knowledge_chunks，按场景分类 + 置信度取素材，以「资深考官」角色（temperature 0.7）生成简单/中等/困难分级的开放式场景题与参考答案。
- 实现 LLM 自动评判：以「资深评审专家」角色（temperature 0.3 保稳定）从实战性、需求把握、销售策略、话术自然度、红线检查五维度逐题打分，按「平均分 ×10」映射百分制，支持人工二次复核校准。
- 针对知识库膨胀到十万级的演进，设计 RAG 出题方案：模糊请求先由 LLM 规划主题 → 多轮向量检索（pgvector/Milvus）→ MMR 去重保多样性，解决固定 top-30 导致题目重复、长尾素材浪费的问题。

基于聊天数据的大模型微调

2026.4-至今

AI 技术负责人

项目规划：

让 AI 客服回复更像真人，基于数据中台导出的 SFT/DPO 数据微调豆包模型，再回灌到项目一的客服系统。

- 微调语料直接来自数据中台：消费中台 approved 的 ShareGPT/OpenAI 格式数据，并将对话分流为两套——SFT 数据（保留多轮上下文学销售话术风格）与 RAG 知识库数据（提炼课程、价格、优惠等结构化知识），践行"微调管风格、RAG 管知识"的职责分离，知识更新只改知识库无需重训。
- 采用「本地小模型验证 + 云端大模型训练」两阶段策略：本地 LLaMA-Factory + Qwen2.5-3B-Instruct 做 QLoRA（rank=64, alpha=128, lr=2e-4），单卡 RTX 4090 约 40 分钟一轮快速验证数据质量；通过后上传火山引擎方舟对豆包 1.5 做生产级 LoRA（rank=32, lr=1e-5），按模型规模等比缩放超参，风格一致性人工盲评从 2.1 提升至 4.3（5 分制）。
- 规划 SFT → DPO 两阶段训练路径：SFT 解决"从不会到会说"的风格模仿；DPO 对同一问题采样多条回复，由销售主管标注 chosen/rejected 偏好对训练优劣区分，解决"会说但说不好"；选 DPO 而非 RLHF 是因其跳过奖励模型训练，在偏好数据有限（几百条）时更稳定、成本更低。
- 构建 Embedding → 向量检索 → Rerank 三阶段 RAG Pipeline：火山引擎 Embedding 向量化 + 向量检索 top-20 粗召回，引入 Cross-Encoder 精排取 top-5，解决双编码器在语义相近文档上区分度不足问题，知识命中率从 72% 提升至 89%。
- 微调后的模型作为 LLM 层接入项目一 RTC 实时语音链路（客户语音 → ASR → RAG → 微调 LLM → TTS → 语音回复），通过微调缩短 system prompt 降低 TTFT，在实时对话场景下保障体验，完成"数据中台 → 微调 → 客服"的回路闭合。

教育经历

重庆财经学院 **2021.9-2025.7**

智能科学与技术 | 本科

在校期间始终保持高度的学习热情与实践精神，参与校园创新项目，团队协作完成方案并获校级奖项。坚持兼职与实习，平衡学业与社会实践，锻炼了扎实的专业能力与高效的时间管理